



深信服AI算力网关：算力治理和vGPU优化实践



2026.04

目录

DIRECTORY

01 Agent时代的算力治理趋势、挑战与应对思路

02 深信服AI算力网关实践

03 vGPU落地实践

Agent应用发展迅猛，带来更多的算力消耗



- OpenClaw全球爆火，能接管电脑自动执行复杂任务，极大解放用户双手，其github star数在发布后3个月内成为历史第一。
- Kimi在2026年头20天的订阅收入超过2025年全年。



- 开放式AI-Agent应用在后台会自动“思考”和“执行”，带来不可控的突发流量。
- AI应用对算力消耗呈指数级增长，IDC预测2030年token消耗将比2025年增长600倍以上。

AI模型和算力的管控、成本、可靠性与安全性问题日益凸显

AI管控难

- 如何管控，保障AI算力都用能用在有价值的业务场景？
- 各部门都说GPU/tokens不够用，是否真的用在价值AI场景不知道，怎么管不清晰
- 管理全靠“人+制度”，缺少技术手段对算力使用做合理控制

成本失控

- 效果好了，成本指数级飙升！
- AI Coding、数字员工等明星AI场景，都用最好效果的模型，要么tokens调用费用极高（1W/人/月起步）！要么本地显卡成本极高（X W/人起步）！

算力供给可靠性差

- 单算力供应商和模型服务，单点故障风险高
- 多算力供应商性能不一致且存在波动，业务不稳定
- 专属算力支撑的业务，难以支撑**突发业务流量**，影响业务稳定和体验

安全风险高

- 应用“裸奔”，隐私数据无管控，权限管理松懈，**企业核心数据资产被盗窃**
- Agent明文传输导致数据泄密
- 用公共Maas服务，客户数据可能被用来训练模型，进而导致数据泄露

应对思路：通过AI算力的可视与有效管控，让算力真正用在价值场景



可视可控

全局各部门、各角色、各类型（Token、GPU）算力使用情况应可视、可审计、可管控

应对思路：通过创新技术突破，实现各类AI算力成本大幅下降



应对思路：应提供灵活的算力负载能力，保障Agent算力使用的可靠性



应对思路：Agent运行的敏感数据与模型推理过程的数据安全同步考虑

敏感数据安全

专属安全算力环境+隐私推理

通过隐私推理技术，将**安全掌控权交给用户线下**，打造可信赖的、合规、安全的AI基础设施。

模型推理安全

模型安全护栏

通过大模型安全护栏，实现对提示词注入攻击的有效检测，以及内容安全检测。

目录

DIRECTORY

01 Agent时代的算力治理趋势、挑战与应对思路

02 深信服AI算力网关实践

03 vGPU落地实践

深信服AI算力网关架构

统一模型接入

- 作为用户AI统一模型接入的网关

本地算力治理

- 纳管本地算力GPU
- 性能优化（支持第三方算力环境部署）

安全推理算力

- 提供基于托管云的安全专属算力

应用层 多个部门、多个业务使用数量庞大的复杂、多样化AI-Agent应用，需要多种AI模型能力

生产级业务Agent

企业智能客服、银行APP助手...

开放、垂直Agent

销售Agent、AI Coding、数字员工、金融研报生成...

部门A

人员1, 2, 3, ...

部门B

日常办公助手, 人员4, 5, 6, ...

网关和模型层




MaaS (Model-As-A-Service)层 多元化算力与模型服务供应

本地算力

专属算力

性能优化

模型接入



让全模型服务接入统一、全局算力用量和内容可视



各种算力来源的模型服务统一接入



全局用量按部门、按路由、按模型、API-Key可视

提供商类型

OpenRouter

硅基流动

阿里云百炼

火山引擎

自定义提供商

基本信息

提供商名称:



全局模型服务统一分发和管理



调用供应商、输入输出 token 和内容、费用、API 类型、吞吐、首Token时延、端到端时延等指标全面可视

Key 名称	总调用量	失败调用	失败率
ACG演示key	374,113	4	0.00%
ba924a14-c106-459f-88f2-3361...	559	-	0.00%
ACG演示-高宇	80	10	12.50%
财务部-张三	47	36	76.60%



总览

模型路由

模型接入

用量统计

API Key

API Key 管理

API Key 是调用模型的重要凭证，请您妥善保管，不要将密钥信息共享至公开环境。

+ 创建

✓ 启用

🚫 禁用

🗑️ 删除

全部启用状态

Key 名称

Q

C

Key名称 (...)	启...	描述	API Key	关联路由数	使用有效期	创建时间	操作
☐ didi 71dd9f07-e1a...	✓ 已...	-		1	永久有效	2026-03-24 14:46:03	编辑 禁用 删除
☒ xixi d701ef75-bf3...	✓ 已...	-		2	永久有效	2026-03-24 14:45:40	编辑 禁用 删除
☐ 语义路由-0323 cf849f12-d58...	✓ 已...	-					编辑 禁用 删除
☐ qewqe 8b772e05-c6...	✓ 已...	-					编辑 禁用 删除

路由名称

0329语义路由

xixi

日志详情

用量及性能

Token 消耗: 总: 713 | 输入: 491 | 输出: 222

费用: ¥0.000000

端到端时延: 3505 ms

首 token 时延: 1098 ms

总吞吐: 203.42 tokens/s

精准权限和控制策略，让每一分算力投入有价值

基于 请求频率、输入输出token、并发连接数、访问限制进行精准限流，限额

创建

×

基本信息

名称:

描述:

关联路由:

关联业务组:

使用有效期: ☒ 永久有效 ☐ 指定时间

☒ 启用限流策略
设置该 Key 可以使用的总量，包含所有关联的路由。

请求频率: 次 / 分钟 ×

+ 添加 当前已配置 1/3 条

输入 Token 数: tokens / 分钟 ×

+ 添加 当前已配置 1/4 条

输出 Token 数: tokens / 分钟 ×

+ 添加 当前已配置 1/4 条

并发连接数:

☒ 启用访问限制

IP 白名单:

确定 取消

基于API Key将权限精细化到组织和部门，让每个部门的算力得到精准控制

深信服AI算力网关
Sangfor AI Computing Gateway

API Key

API Key 是调用模型的重要凭证，请您妥善保管，不要将密钥信息共享至公开环境。

+ 创建 ✓ 启用 禁用 删除


全部业务组 全部启用状态 Key 名称

☐	Key 名称 (ID)	启用状态	描述	API Key	关联路由数	使用有效期	限流	白名单	所属业务组	创建时间	操作
☐	Key1 ID1////////	✓ 已启用	-	sk-a3...	8	永久有效	无限制	-	组1	2026-02-22 18:00:00	查看用量 禁用 更多
☐	Key2 ID1////////	✓ 已启用	-	*****	10	2019-12-09 18:00:00 已过期	无限制	10.10.10.1	组1	2026-02-22 18:00:00	查看用量 禁用 更多
☐	Key3 ID1////////	✗ 已禁用	-	*****	6	2019-12-09 18:00:00	无限制	10.10.10.1	组1	2026-02-22 18:00:00	查看用量 启用 更多

共 4 条 < 1 > 每页 50 条 前往 1 页


统一模型接入 - 智能路由引擎让模型费用有效降低

ClaudeCode所有问题都使用顶尖模型，成本非常高



*2000人研发团队一个月调用外部模型费用

使用智能路由引擎对接ClaudeCode，成本下降



*使用智能路由引擎后，2000人研发团队一个月调用外部模型费用

本地算力治理 - 智能融合架构，让多卡多模型复杂性屏蔽



本地算力治理 - 面向重载Agent应用落地，专属算力ROI提升2~5倍

基于客户业务应用场景化调优，提升AI应用端到端性能

自适应模块分析业务画像定位瓶颈。

自适应原子能力解决不同性能瓶颈。

Agent应用

企业级
openclaw

卫宁健康



衡石



派兹



鼎捷软件



东华医为



...

自适应架构层Smart Arc

自适应
模块

自适应多版本推理引擎

自适应多类型推理引擎

性能瓶颈分析

自适应调整

回流数据观测

一键最佳实践配置

指标采集

开源推理框架/自研推理框架：SIF (Sangfor Inference Framework)，加密、可

靠优化、性能优化

自适应
原子能力

AI 网关智能负载调度、限流、计量

基于检索的投机解码优化

算力资源自适应，MOE算子优化

基于场景化的分块调度优化

GPU间、节点间数据传输优化


基于场景语义感知的Cache智能负载

长输入性能优化

昇腾优化

.....


✓ 灵活交付调优效果



本地深信服算力平台GPU资源池

本地第三方算力平台GPU资源池

✓ 多行业场景Agent优化案例



本地算力治理 - vGPU+API Key管理, 算力利用率成倍提升, 模型使用更便捷

支持算力1%, 256MB级显存资源切分

Openclaw、智能客服等AI应用都需要大量小模型运行在vGPU上


vGPU

显卡消耗

显卡越高端


模型使用越多

越省钱



单卡承载模型数量翻8倍+

现有资源利用率同比3倍+




Sangfor-vGPU

Agent算力消耗可视

模型服务多KEY精细化运营, 显卡资源利用率倍增

重要Agent体验保障


N部门N模型, 模型服务高效共享, 一键限流非关键业务




统一模型接入 - 模型聚合路由让各场景算力供给更可靠

避免多来源模型单点故障，保障服务流畅稳定，云上云下模型弹性切换，提升AI业务健壮性

- 配置跨本地资源池、跨模型供应商的轮询调度策略：避免业务高峰单点模型服务过载故障
- 配置本地算力+云端模型优先级策略：优先使用私有算力，达到负载阈值自动分流云端模型，缓解高峰压力



“单点故障风险降低，主模型故障时业务中断时间由 1 小时降到 10 分钟以内”



“在 3 倍峰值流量压测下，采用云上云下弹性策略，模型调用成功率维持在 95%+，核心AI业务韧性显著增强。”

提供大模型安全护栏，保护AI安全

以AI保护AI

- 核心能力构建于大模型之上
- 一流的攻防积累

对接灵活可靠

- 将业务影响降至最低
- 适配方式灵活


效果好性能强

- 专业垂域模型
- 大小模型组合架构
- 推理算法优化

安全in网关

- 内置安全护栏，一键开启，按需选择保护范围
- 调用日志、告警联动

以大模型安全护栏为核心的安全防护方案



目录

DIRECTORY

01 Agent时代的算力治理趋势、挑战与应对思路

02 深信服AI算力网关实践

03 vGPU落地实践

vGPU整体思路介绍

目标：面向 batch、gang 与 LWS 场景的共享 GPU 控制面优化


技术关键词



主命题

共享 GPU 在作业调度场景下，控制面需要同时做好状态维护、资源管理和任务调度

包括包括平台选型前提、Volcano 与 HAMi 的能力分工，以及共享 GPU 在 gang 和 LWS 场景中的四类控制面优化点



平台选型要点：作业级调度能力是共享 GPU 落地的上层约束

batch、gang 与 LWS 语义决定了共享 GPU 需要接入 Volcano 的作业级路线



vGPU能力底座：HAMi提供细粒度切分与容器隔离

设备层方案需要在通用 GPU 条件下提供切分、限制与透明接入能力

Full-card

整卡分配

部署前提
无需额外前提

资源粒度
整卡

硬件依赖
无

适用场景
强隔离 / 低复用

Dynamic MIG

硬件切片

部署前提
需要 Ampere 及以上

资源粒度
MIG 硬件切片

硬件依赖
强依赖 MIG GPU

适用场景
性能隔离要求强

HAMi-core

软件隔离 + 细粒度切分

部署前提
软件隔离路径

资源粒度
显存 / core / SM

硬件依赖
不要求 MIG

适用场景
通用训练与推理

HAMi 将共享 GPU 做成可接入的设备能力底座

device memory

device core

container-side limit

app transparent

no MIG baseline

这一层关注设备切分、容器内限制和应用透明性，并为上层作业编排提供统一的共享 GPU 能力接口。

能力分工：Volcano 负责作业编排，HAMi 负责设备共享

共享 GPU 的稳定运行取决于作业级语义与设备级语义之间的控制面衔接

上层工作负载关注整组任务启动、放置与生命周期管理：Batch jobs / Gang jobs / LWS workloads

Volcano orchestration

Volcano 承接作业级调度语义

batch scheduling
Gang / PodGroup
Queue / Quota
Topology
LWS integration



HAMi virtualization

HAMi 与 device plugin 承接设备级共享语义

device memory / core split
device exposure
node-side limit
GPU UUID policy
sharing baseline


控制面衔接层将作业级语义与设备级语义连接到同一条调度链路

设备状态维护 | 调度事务收敛 | 入口治理 | 整组任务放置

设备状态持续进入调度视图 | 试算快照与生命周期同步 | 资源语义在入口统一 | 拓扑与 vGPU 可分配性联合判断

GANG / LWS 场景，我们重点优化了哪些调度器控制面环节

设备状态维护、入口治理、调度事务收敛和整组任务调度



共享 GPU 进入 gang 和 LWS 场景后，控制面需要同时兼顾设备侧管理和作业侧调度；后续内容将围绕这几条关键链路逐一展开。

device semantics

job semantics

control-plane closure

优化点一：设备状态维护从一次性快照升级为持续维护对象

节点设备状态通过周期检查进入调度和监控共用的状态视图

Before

调度阶段读取节点快照

Node annotation

节点一次上报设备状态

Passive read

scheduler 被动读取

Residue kept

过期 handshake、异常设备和残留 metrics 继续留在系统里

旧模式的问题是控制面只在读取时刻看到状态，之后缺少持续维护动作。

After

维护链路将设备状态接入周期检查与结果收敛

volcano.sh/node-vgpu-register

volcano.sh/node-vgpu-handshake

节点状态

register /
handshake /
device info

周期循环

device maintenance

健康检查

timeout check
health check

状态同步

deleted mark
cache update

维护行为

握手超时处理

握手超时进入过期处理

健康检查过滤

故障卡从可调度视图中剔除


监控数据清理

清理与节点状态不一致的指标残留

控制面周期识别超时与异常，并将结果同步到设备状态与监控视图。

优化点二：入口准入与资源治理统一共享 GPU 资源语义

资源字段补齐、派生总量和一致性校验在入口完成



优化点三：调度事务通过隔离预分配计算快照与生命周期同步收敛

调度阶段与真实占用阶段保持一致口径，但不共享同一份可变状态



优化点四：整组任务放置需要联合判断拓扑与 vGPU 可分配性

常规资源满足条件，不代表整组任务在当前设备布局下可以成功分配设备完成调度



节点 A 的常规资源满足条件，但当前设备布局不能满足这一组任务的 vGPU 需求



binpack spread

判断单位从单个 Pod 转为整组任务，多维度与设备可分配性在同一轮调度决策中完成计算


官网 <https://costrict.ai/>




COSTRICT

微信扫描二维码，关注我的帐号

VS Code 1.86.3 及以上版本



JetBrains IDE 2023.3 及以上版本





谢谢聆听

让每个用户的数智化更简单、更安全！

