

BoardWare x HAMi GPU 虛擬化與集群管理研發歷程分享

April 25th, 2026

博維聚力·智創未來

BoardWare Intelligence Innovates the Future



博維智慧
BoardWare
(1204.HK)



神州投資



博維資訊系統有限公司

BOVISION



小南科技

MechCare

澳門 · 香港 · 橫琴 · 廣州 · 北京



集團業務

新一代數字解決方案服務



人工智能方案



次世代系統
集成平臺



IT解決方案



智能化工程

增值科技服務



資訊安全
託管服務



系統託管服務



創意數字內容



機器人服務

自主及產學研合作研發產品



行業大模型
訓練技術



感知與腦機
交互產品



系列產學研
合作產品

Empowered by 

- ▼ 成立於2010年，澳門首家及目前唯一登錄港交所主板科企(1204.HK)
- ▼ 2023年獲澳門經科局首批認證為三大「重點科技企業」之一
- ▼ 2024年成為首家科企獲澳門特區政府頒授「工商功績勳章」
- ▼ 人才超卓——近400名員工，技術人才佔比超75%

發展歷程 Development Milestones

2010 

創立澳門博維資訊
於澳門開展提供企業IT解決方案服務



2016

完成六個澳門大型綜合度假村項目



2017  

成立珠海博維 收購智揚科技 成立香港博維



2018

成立澳門首個本地化ISO 27001 信息安全營運中心



2019

榮獲澳門中小企優秀獎



2021 

成立廣州博維
● 與澳門大學組建聯合實驗室
● 小舟科技團隊籌建



2022  

港股主板上市 HKEX : 01204

- 與廣東省智研院建立腦機元宇宙數字融合聯合實驗室
- 成立鵬城境外聯合網絡靶場
- 珠海博維獲高新技術企業認證
- 澳門小舟成立



2023 

獲澳門政府首批認證最高級別的「重點科技企業」

- 與北京航天航空大學建立聯合實驗室
- 舉辦首次科研成果發佈會
- 舉辦賦能中小企數字化發展項目啟動發佈會暨與MGM簽約儀式
- 成立北京小舟、北京小舟腦機研究院



2024 

成為首家科企獲澳門政府頒授「工商功績勳章」

- 獲中央港澳辦主任、國務院港澳辦主任夏寶龍到訪指導
- 與浙江大學建立聯合實驗室
- 成立神舟商業投資及管理有限公司及其首個合資公司BOVISION



2025 

發佈「博維次世代自研AI矩陣」

- 獲橫琴「綜合貢獻獎」
- 獲澳門「最具價值品牌大獎」
- 獲廣東「專精特新中小企業」認證
- 獲選橫琴「育苗培優」計劃之首批「培優」企業
- 成立眾芯機器人服務有限公司



未來可期

澳琴首選 IT 合作夥伴

澳琴最大規模的本地資源

- 澳琴兩地已逾**300名員工**
- **80%**為持有專業認證的資訊科技人員及專家
- 安全運營中心（SOC）、網絡運營中心（NOC）與備件庫

無可比擬的榮譽

- 澳門首家IT公司獲評「**重點科技企業**」
- 澳門首家科技企業榮獲「**工商功績勳章**」
- 「**專精特新中小企業**」認證

全方位支援

- 專業服務（PS）、維保服務（MA）、託管服務（MS）、項目管理辦公室（PMO）及售前（Presales）團隊
- 與澳門及內地高校/科研機構共建4個聯合實驗室+2個網絡安全靶場實驗基地
- 離岸研發及開發團隊
- 人工智能/腦機接口/物聯網專業團隊
- 配備CPU/GPU算力的跨境數據中心
- 創意數字內容開發

智能體

大語言模型訓練
視覺語言模型訓練
LRM 模型訓練
多智能體系統

AI 原生

AI 容器化持續集成與持續部署
大模型推理
一鍵式 API 部署
多模態數據合成
統一基礎設施

諮詢與培訓服務

基礎設施設計
AI 與雲端技術教育培訓
AI 解決方案諮詢


具身智能研究

視覺-語言-動作模型
機械人遙操及操作
人機交互



初期開發方式

NVIDIA vGPU ARCHITECTURE CONCEPT



使用NVIDIA vGPU + VM

需要NVIDIA vPC/vCS授權

不能動態改變vRAM大小

不適合大規模參數模型訓練

初期轉變——擁抱云原生架構



早期：傳統虛擬機部署

- 基於傳統虛擬化技術，部署流程複雜。
- 環境與硬體耦合度高，遷移成本昂貴。
- 算力分配以「整機」為單位，資源利用率存在瓶頸。

突破



現在：容器化與 Kubernetes

- 全面擁抱 **Docker 與 K8s** 體系，實現開發環境標準化。
- **突破架構限制**：從虛擬機過度到輕量化容器，算力調度更靈活。
- 為之後 **AI云原生平臺** 的研發奠定基石。

從單一的虛擬機環境轉向 **雲原生架構**，是我們實現「算力調度自由」的關鍵一步。

使用云原生初期探索成果

早期攻关

從零建立跨卡跨節點訓練環境，建立起大參數視覺模型訓練方式。

標準化

將 TTS、LLM、ASR 等模型全面容器化，像搭積木一樣建立起流暢的 AI 管線。



初期現狀：深耕模型訓練與推理

我們最初以「科研小作坊」模式運作，專注於大模型底層的訓練與推理優化，累積了大量的實戰經驗。

曾走過的彎路：平台之困

為了提升效率，我們前後測試了多款主流容器平台進行開發，但結果卻不如預期：

- **配置繁瑣**：環境初始化耗時過長，需要重複配置環境。
- **調度僵化**：難以靈活分配算力，資源爭搶嚴重。
- **環境割裂**：服務難以維護，缺乏統一的生命週期管理。
- **成本增加**：團隊學習成本高，硬件漸漸增多導致管理困難。



「平台不但沒幫上忙，
反而成了研發的負擔」

ERROR: Config Mismatch...
ERROR: GPU Driver Timeout...
ERROR: Resource Deadlock...

轉機——爲了「好用」而生的部署平臺

💡 客戶的啟發

正當我們為開發工具發愁時，客戶提出了一個明確的願景：

「我們不想要複雜的配置，我們想要 **一鍵部署**。模型跑起來後，我們能立刻開始業務開發。」



🔧 初心：既然沒有好用的，就自己造

我們意識到，一個「自用」與「客用」皆優的平台是 AI 落地的關鍵。這促使我們決心研發：

One Click Deployment Platform(OCDP)

🚀 OCDP 的核心產品理念



極簡部署

一鍵部署新鏡像與模型



支持異構

跳過基礎設施坑洞



高效運維

大規模集群管理

由此，OCDP 正式進入了算力深水區，開始了解決 GPU 碎片化的探索之旅...

Boardware - OCDP

產品初衷：解決客戶底層算力調度及服務管理的痛點

計算資源納管

互動介面與控制台

任務管理

一鍵部署大模型推理、訓練服務

- 納管算力設備與服務器，方便計算資源調度，區分不同資源組；
- 透過簡潔的界面管理和監控平台；
- 提供多種模型加速框架，支持根據模板一鍵建立大模型服務；
- 支援一鍵部署大模型推理服務、快速構建 LLM API 業務；
- 將大模型整合到實際業務場景中，為企業提供智慧化服務；
- 軟硬件協同優化，算力親和性調度，提升計算效率。

Layer 1 (User Interface)



Users




Administrators

Layer 2 (Management & Orchestration)



Layer 3 (GPU Resource Scheduling)

GPU Task Scheduling
GPU 任務調度



Layer 4 (Infrastructure)





Boardware AI 算力調度平台

One Click Deployment Platform

效能驗證——模型推理實測數據

科研探索：推理能力深度見解

精度與吞吐平衡：針對不同參數規模，研究不同量化精度對推理精準度與吞吐量的邊際效應。

動態顯存管理：優化多租戶併發下的 KV Cache 分配，減少 VRAM 碎片化，提升長文本處理能力。

硬體適配矩陣：建立模型規模與算力需求的對應模型，為客戶提供最佳的「成本-效能」硬體組合建議。

專家價值：我們不只是部署模型，更能根據客戶業務需求提供底層優化方案。

實測驗證：InfiniBand 網絡價值

壓力測試：200 User / 30 mins 持續併發

網絡架構	總請求	RPS
傳統以太網絡	30,190	19.2
IB/RDMA	48,713	29.9

+38%
高併發承載

+42%
響應延遲



透過對「分佈式架構」與「高速網絡」的持續科研與實測，我們能根據客戶的硬體預算，提供最具實戰價值的模型推理與部署建議，確保每一片 GPU 都能發揮其最大潛能。

探索之路——早期集群監控嘗試

💡 核心內容

- 初始方案：使用 NVIDIA `gpu-operator` 進行基礎納管。
- 遇到的牆：雖然能看到實體卡狀態，但無法感知「誰佔用了多少、顯存碎片化嚴重」等深層資訊。



⚠️ 基礎監控

NVIDIA-SMI 588.95.05 Driver Version: 588.95.05 CUDA Version: 13.8				NAME	READY	STATUS	RESTARTS	AGE
				gpu-feature-discovery-8lchg	1/1	Running	0	2d1h
				gpu-feature-discovery-9pt6n	1/1	Running	2 (22d ago)	56d
				gpu-feature-discovery-fdv7w	1/1	Running	0	56d
				gpu-operator-1755487136-node-feature-discovery-gc-f596cf76czzzj	1/1	Running	0	56d
				gpu-operator-1755487136-node-feature-discovery-master-85cbdpkc7	1/1	Running	3 (56d ago)	56d
				gpu-operator-1755487136-node-feature-discovery-worker-kccrw	1/1	Running	10 (2d18h ago)	25d
				gpu-operator-1755487136-node-feature-discovery-worker-mlsvv	1/1	Running	178 (12d ago)	234d
				gpu-operator-1755487136-node-feature-discovery-worker-q5ptx	1/1	Running	2 (27d ago)	56d
				gpu-operator-6db595674c-z8vpt	1/1	Running	3 (56d ago)	56d
				nvidia-container-toolkit-daemonset-5dbhz	1/1	Running	0	2d1h

僅提供基本狀態

🔍 深度拓撲



缺乏可視化與深層指標

進階需求——為什麼需要GPU虛擬化

🎯 核心場景與客戶訴求

場景一：AI 互動數字人管線

整合 ASR + LLM + TTS 的即時交互鏈路

- 各組件顯存需求差異大，整卡分配導致 70% 資源浪費
- 通過切分，可在單卡內併發運行多套數字人引擎

場景二：私有化 Agent 沙箱

多用戶同時運行私有 Agent 或進行模型微調調試

- 支持用戶按需申請 **0.2 塊卡** 或 **4GB 顯存**
- 大幅降低研發環境門檻，資源周轉率提升 3 倍以上

⚡ 多務並行資源切分示意



算力隔離 與 彈性顯存
確保關鍵推理任務互不干擾

選擇理由

HAMi 不僅提供了強大的 **GPU 虛擬化（切割）** 能力，適配不同的卡型，還自帶了詳盡的 **集群監控** 指標。

 頂層：One Click Deployment Platform (OCDP) 平台

↑ 管理與調度 ↓

 中間層：HAMi (算力手術刀與顯微鏡)

↑ 虛擬化與監控 ↓


 底層：實體 GPU 硬體資源

深度實踐——監控透明化與資源高效利用

核心實踐

- **監控**：OCDP 整合 HAMi 指標，實現從實體卡到虛擬維度的 Grafana 即時看板。
- **切割**：支援用戶在 OCDP 申請「0.5塊卡」或「10GB顯存」，大幅提升算力資源周轉率。


接入前 - 可監控集群資源基礎信息，但缺失顯卡資源的詳細指標



接入后 - 能清晰的看到虛擬現存的狀態以及更多物理顯卡的監控信息



案例1 —— 多集群矩陣治理




📌 典型集群：多業務混合調度

- **輕量級任務 (ASR/OCR)：**利用 HAMi 顯存切割，在單卡實現高併發小模型部署。
- **核心推理 (LLM)：**分配穩定算力配額，確保低延遲首字響應 (TTFT)。
- **模型訓練 (Training)：**利用剩餘算力進行離線微調，實現 **在/離線混部**。
- **強隔離機制：**確保 ASR 突發流量不干擾 LLM 推理穩定性。

🌐 全局矩陣佈局

我們目前同時管理著 **多個地理分佈的集群**。每個集群均具備同等的資源治理能力，通過 OCDP 平台實現跨集群的資源自動化調度與高可用災備。

案例2 —— OpenClaw-RL 結合HAMi部署




12 卡環境核心挑戰與優化策略

- **拓撲感知調度**：強制將 Megatron (Training) 綁定於 Node A 的 6 張卡，確保 NVLink 頻寬，**絕對避免跨節點訓練**。
- **vGPU 顯存隔離**：針對 PRM 與 SGLang 進行顯存硬隔離切片，防止突發推論流量導致 OOM 骨牌效應。
- **異步工作流映射**：將 Environment Hosting 剝離至純 CPU 節點，GPU 資源 100% 留給模型。

高效資料流閉環

Agent 於 Node B 產生交互軌跡 → Node A 的 PRM 進行獎勵評估 → Megatron 進行非同步梯度更新 → **定時將權重同步回 Node B**。

案例3 —— HAMi多場景算力應用



三大核心研發場景賦能

- **多租戶演算法實驗室**：利用 HAMi 為 Jupyter 實例進行顯存硬隔離與算力超賣。研究員的 OOM 錯誤僅限於自有 vGPU 內，**互不干擾**。
- **CI/CD 自動化測試**：Pipeline 觸發時動態申請小粒度資源，單卡並行多個單元測試，結束後**秒級釋放**資源。
- **多模態微服務混部**：將大顯存精準劃分，確保 LLM 享有最佳 PCIe 拓撲。

戰略價值：打破實體邊界

HAMi 將原本利用率不足 30% 的硬體孤島，轉變為**高度彈性、按需分配的 AI 算力雲**。

願景與展望——邁向異構算力納管

打破硬體壁壘，建構無限擴展的算力矩陣



「讓客戶不再為底層硬體差異發愁」

擁抱異構生態

期盼 HAMi 持續進化，從底層屏蔽硬體差異，完美相容 AMD 以及華為、摩爾線程等多元國產顯卡架構。

算力無縫納管

透過 OCDP 平台，無論底層是何種晶片，皆能實現統一監控、混合調度與靈活切片，打造真正的全局通用智算叢集。

釋放極限生產力

告別單一供應商綁定 (Vendor Lock-in)。算力管理不僅是技術的堆疊，更是為企業營運降本增效、尊重生產力的最佳實踐。



Thank you !