

The Infrastructure of AI's Future

演讲人 - 陈泽辉 (Keith Chan)










CNCF China Director, Linux Foundation APAC 亚太区副总裁

CNCF Annual Survey

重点:

1. Kubernetes已从容器编排器发展为 AI 基础设施平台，已有66%的企业在运行中 其上运行的生成式人工智能工作负载。


2. 47%的组织只有偶尔部署了人工智能模型，52%的组织根本不训练模型。真正的竞争优势不在于算法，而在于乏味的基础设施能力：强大的CI/CD管道及资源优化。



Kubernetes as the AI Platform

重点:

- 1. 66%的组织押注Kubernetes运行其生成性AI工作负载。然而，成功取决于能否应对资源管理以及管道部署的挑战
- 2. Kubernetes提供一个统一的编排层来处理传统的应用程序工作负载和计算密集型AI任务。Kubeflow等项目提供端到端的机器学习工作流，而KServe则处理大规模的模型服务。HAMI把GPU调度功能、和复杂的资源配额管理的引入使组织能够高效地共享昂贵的硬件资源。




Most Organisations are consumers of AI

重点：

- 1. 大多数组织是人工智能模型的消费者。52%的受访组织不构建或训练人工智能模型。
- 2. 这对基础设施需求有影响，因为推理工作负载需要不同的可扩展性和成本优化策略。推理是连续运行的，这使得成本管理变得至关重要。组织实施复杂的自动缩放策略，可能使用基于CPU的推理，用于要求较低的工作负载，并为延迟敏感的应用程序保留GPU资源。


FIGURE 2
AI HOSTING

Does your organization host generative AI models for **inference**? If so, where? (select all that apply)



2025 CNCF Annual Survey, Q39, Sample size = 497, DKNS excluded.

Does your organization host generative AI models for **building and training**? If so, where? (select all that apply)



2025 CNCF Annual Survey, Q40, Sample size = 482, DKNS excluded

Infrastructure-first Approach

在AI方面取得成功的组织不仅仅是那些拥有最好模型的组织。他们是那些基础设施成熟的组织，能够可靠地部署和扩展这些AI工作负载。Kubernetes正在成为基础，但成功需要将AI/ML视为一流的基础设施挑战，而不仅仅是算法挑战。

“We reduced CPU usage of Fluent Bit by 50% across our entire fleet, providing much-needed capacity to our entire research and applied infrastructure. This is the power of the CNCF ecosystem, when you deeply understand these tools, you can optimize them in ways that benefit everyone.” - **FABIAN PONCE, MEMBER OF TECHNICAL STAFF, OPENAI**

KUBECON + CLOUDNATIVECON CHINA



iFlytek—Training massive AI models at scale is tough—but doing it efficiently in Kubernetes is even tougher. iFlytek tackled key challenges in large-scale model training, including low GPU utilization, fragile workflows, and resource contention across teams by leveraging Volcano. They were able to boost GPU usage by over 40%, cut failure recovery time by 70%, and accelerated hyperparameter tuning by 50%.

Kubernetes AI Conformance Program

随着人工智能工作负载越来越依赖Kubernetes（82%的组织构建自定义人工智能，58%的组织使用Kubernetes，90%的人认为开源至关重要），碎片化的风险很高。为了解决这个问题，CNCF于2025年启动了Kubernetes AI合规认证计划。

目标很简单：确保Kubernetes可以在任何兼容的平台上以可移植、可靠的方式运行AI工作负载。——能够根据成本、延迟或区域要求在兼容的平台提供者之间移动推理集群是一种竞争优势。

人工智能工作负载是资源密集型和昂贵的




Certified Kubernetes - AI Platform (19)

<https://github.com/cncf/k8s-ai-conformance>

样本概况：155家企业，覆盖全国8大区域


区域分布

样本呈现显著产业聚集特征，**华东（31.0%）与华北（27.7%）** 合计占比**58.7%**，反映AI产业向经济发达地区集中布局的现实格局。



企业规模与业务领域分布

500人以上大型企业占比43.9%，中小微企业（0-200人）合计占**40.6%**，样本结构与行业实际分布高度吻合。业务领域以**AI平台/基础设施企业为主（56.1%）**，底层技术支撑企业主导云原生需求。



第二章 · 云原生技术应用现状

📊 技术渗透率

90.3%

云原生采纳率

140家企业已应用或计划应用，云原生已成AI企业"标配"技术选择

42.6%

已大规模应用

66家企业完成大规模落地，技术成熟度显著提升

36.8%

小规模试点阶段

57家企业仍处试点期，具备较大规模扩展潜力


9.7%

暂未使用

仅15家企业尚未引入，采纳率已接近行业全覆盖

云原生在AI业务中的核心应用场景


在已应用或计划应用云原生的140家企业中，**大模型训练/推理部署提及率高达72.1%**，位居首位。AI服务高可用保障（49.3%）与AI业务弹性扩缩容（48.6%）紧随其后，深刻印证云原生在解决算力调度与业务稳定性核心痛点上的不可替代性。



行业融合趋势：CNCF AI一致性计划与生态协作

CNCF AI一致性计划关注情况

CNCF（云原生计算基金会）推出的AI一致性计划作为云原生与AI融合的重要行业标准，已获广泛关注。**51.6%的企业已深度关注**该计划，27.7%表示有进一步了解意愿，合计近八成企业对该标准保持积极态度，反映行业对AI与云原生融合规范化的强烈诉求。



行业深度协作意愿

企业参与行业生态共建的意愿尤为突出。**82.6%的企业（128家）明确表示愿意参与LFOSSA后续组织的深度调研活动**，包括专家访谈、案例分享等形式，仅17.4%拒绝参与。


这一数据强烈表明，业界对**共建人才培养体系、共享云原生最佳实践**存在高度共识与迫切期望，为行业协作奠定了坚实的群众基础。

82.6%

愿意参与深度协作

17.4%

暂不参与



技术融合不可逆

90.3%的企业已应用或计划应用云原生，大模型场景驱动下两者深度融合将持续加速，成为行业不可逆趋势。



认证价值凸显

认证从"可选"升为"必需"——76.8%的企业拥有持证人才，61.3%计划未来推动认证，认证已成人才能力评估核心标准。



需求缺口显著

超六成企业计划推动认证，但持证人才集中于头部企业，中小微企业在认证培训与资金投入方面存在明显缺口。



标准需求迫切

逾半数企业关注CNCFAI一致性计划，82.6%愿意参与行业协作，对统一技术标准与生态共建的诉求极为迫切。

第四章 · 认证需求驱动因素分析

在95家计划推动认证的企业中，驱动因素呈现鲜明的"业务导向"特征——认证已从"个人能力提升工具"逐步演变为企业赢得竞争与项目的**业务发展刚需**。



AI业务规模化云原生支撑能力提升

提及率 **66.3%**（63家）——随着大模型推理、训练负载急剧增长，企业迫切需要具备云原生能力的技术人才支撑规模化运营，这是推动认证的首要驱动力。



行业竞争压力 增强团队竞争力

提及率 **56.8%**（54家）——AI行业人才争夺激烈，认证成为企业彰显技术实力、吸引优质人才与客户的重要差异化标志。



AI项目明确要求认证资质

提及率 **50.5%**（48家）——政企大客户项目、云服务招投标等场景中，云原生认证资质已成硬性门槛，倒逼企业加速布局持证人才梯队。

HAMi 除了在互联网、公有云、私有云等领域外，在金融、证券、能源、运营商、教育、制造业等垂直领域，也得到了广泛采纳。超过 40 家企业和机构不仅是最终用户，同时也是活跃的贡献者。

NIO

600

GPUs across 80 nodes supporting autonomous driving workloads

NIO improves GPU utilization for autonomous driving workloads with HAMi

March 17, 2026

READ CASE STUDY

Ke Holdings Inc.

3x

improvement in platform GPU utilization

Scaling machine learning infrastructure with GPU virtualization using Kubernetes and HAMi

February 5, 2026

READ CASE STUDY

DaoCloud

> 80%

Average GPU utilization after vGPU adoption

Building flexible GPU clouds with HAMi at DaoCloud

December 2, 2025

READ CASE STUDY

SF Technology

Up to 57%

GPU Savings for production and test clusters

Effective GPU: A Heterogeneous AI Virtualization Pooling solution by SF technology built on top of HAMi

September 18, 2025

READ CASE STUDY

Prep EDU

90%

of GPU infra optimized using HAMi

Enabling Efficient GPU Orchestration for AI Inference at PREP EDU

August 20, 2025

READ CASE STUDY

PROJECT INSIGHTS

Key metrics, providing insights into development activity, community engagement, and project health. Powered by **LFX Insights**.



HEALTH SCORE
Excellent (81)


Health Score measures a project's overall trustworthiness across four key areas: contributors, development, popularity, and security.



TOTAL CONTRIBUTORS
2,608
+66% vs. previous year



GITHUB STARS
2,255
+61% vs. previous year



SOFTWARE VALUE
\$8.0M



TOTAL CONTRIBUTING ORGANIZATIONS
537
+82% vs. previous year



GITHUB FORKS
493
+57% vs. previous year



FIRST COMMIT
March 15, 2020

[EXPLORE MORE INSIGHTS](#)

8-9 SEPTEMBER 2026

2026年9月8日至9日

SHANGHAI, CHINA | 中国上海

#KUBECON #CLOUDNATIVECON

#OPENINFRA SUMMIT #PYTORCHCON



KubeCon



CloudNativeCon



OpenInfra
SUMMIT > ASIA



PyTorch
CONFERENCE

China 2026

REGISTER

登记

SUBMIT TO THE CFP

提交议题

SPONSOR

赞助